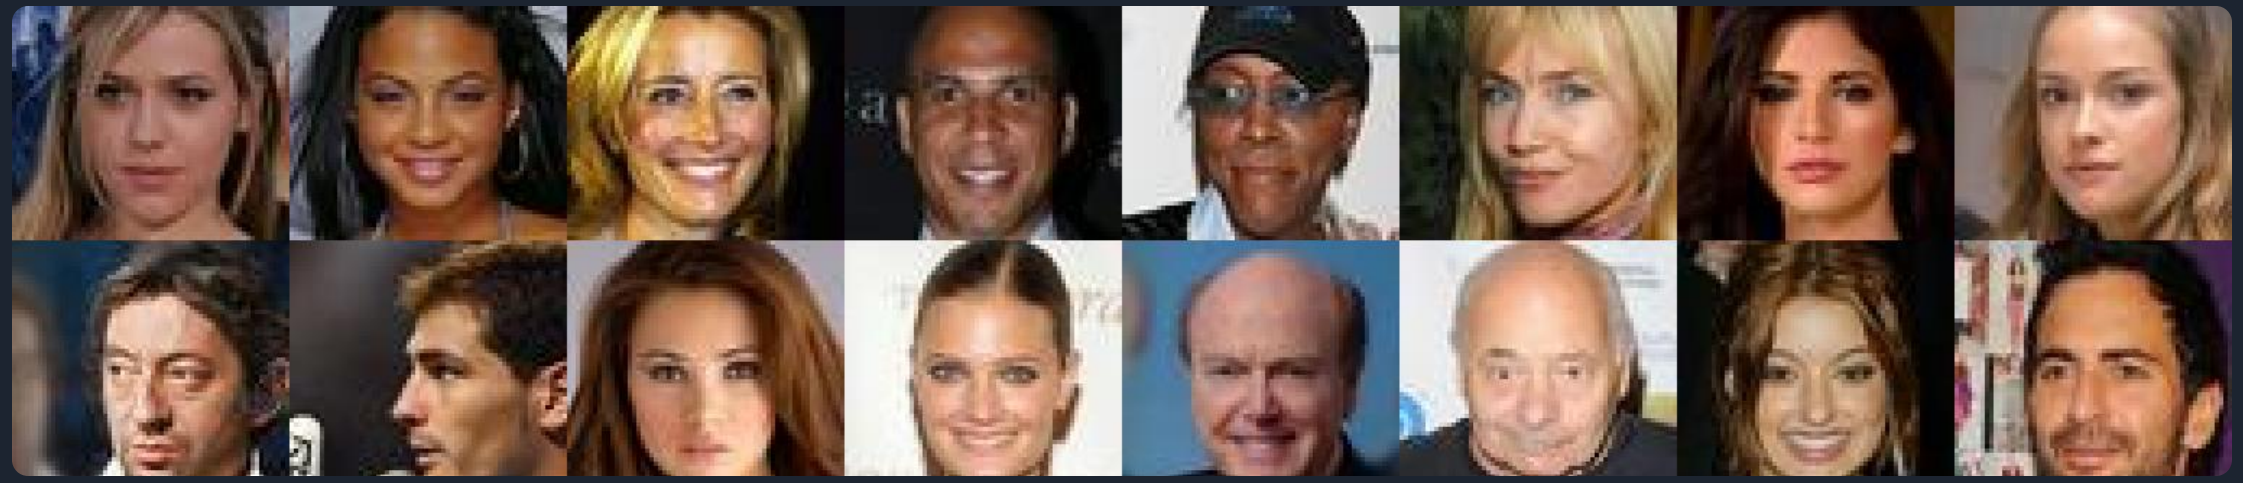
MÉTODOS GENERATIVOS · PRÁCTICA 1

Generando caras con AE y VAE

[Grupo 3] · [Victor Pastor] · [Eric Lugo] · [Andrea Varas] · [Maria Jose Garcia-Prieto] · [Maria Boatella]



ARQUITECTURA 1 · AUTOENCODER

Encoder

```
Entrada 64×64×3
Conv 32, stride 2 → BN → LReLU
Conv 64, stride 2 → BN → LReLU
Flatten → Dense 128
```

z · 128

Decoder

```
Dense 16·16·64 → BN → LReLU
ConvT 64, stride 2 → BN → LReLU
ConvT 32, stride 2 → BN → LReLU
ConvT 3 · sigmoid → 64×64×3
```

Stride 2 en vez de MaxPool

La red aprende cómo reducir (64 → 32 → 16) y el decoder lo deshace con ConvT de stride 2.

BN + LeakyReLU

Activaciones en una escala estable y sin neuronas muertas: entrena más rápido y estable.

Sigmoid + MAE

Salida en [0, 1] como la entrada. Adam, batch 128, 70 épocas, 4,29 M parámetros.

ARQUITECTURA 2 · AUTOENCODER VARIACIONAL

Encoder

```
Conv 32, stride 2 → BN → LReLU
Conv 64, stride 2 → BN → LReLU
Flatten (16.384)
Dense μ (128) · Dense log σ² (128)
```

$$z = \mu + \sigma \cdot \varepsilon$$

Decoder

```
Dense 16·16·64 → BN → LReLU
ConvT 64, stride 2 → BN → LReLU
ConvT 32, stride 2 → BN → LReLU
ConvT 3 · sigmoid
```

Reparametrización

Muestreamos ε ~ N(0, 1) fuera de la red para poder retropropagar a través de μ y σ.

Pérdida = MAE + KL / 12.288

El MAE es una media por píxel (64·64·3). Escalar la KL igual equivale a suma de errores absolutos + KL.

Misma base que el AE

Mismas capas, BN y LeakyReLU, para compararlos de forma justa. Batch 32, 70 épocas, 6,38 M parámetros.

PRUEBAS REALIZADAS

Versión	Cambio	Pérdida	Épocas	Val. final	Mejor val.
AE v1	Conv + MaxPool, sin BN	MSE	5	0,0066	—
AE v2	+ BatchNorm	MSE	70	0,0063	0,0059 (ép. 20)
AE final	Stride 2 + BN + LeakyReLU	MAE	70	0,0513	0,0502 (ép. 43)
VAE v1	Stride 2, Dense 256, sin BN	MSE	70	0,0089	0,0085 (ép. 16)
VAE final	Base del AE, batch 32	MAE	70	0,0535	0,0510 (ép. 35)

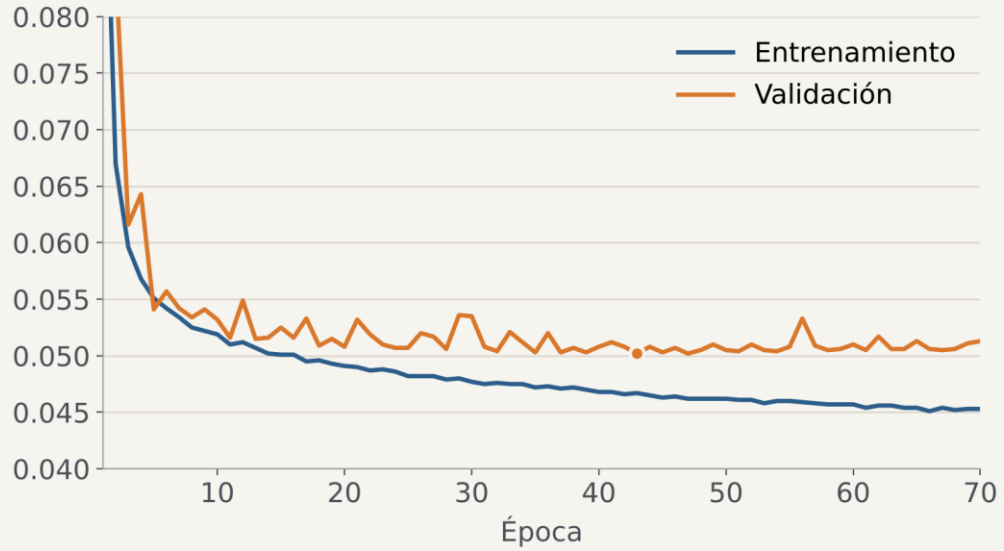
Ojo: MSE y MAE miden cosas distintas, así que sus valores no se comparan entre filas. El cambio se valora mirando las imágenes.

Fallos corregidos: la gráfica de la VAE pintaba el historial del AE, y al generar con la VAE ahora usamos solo μ.

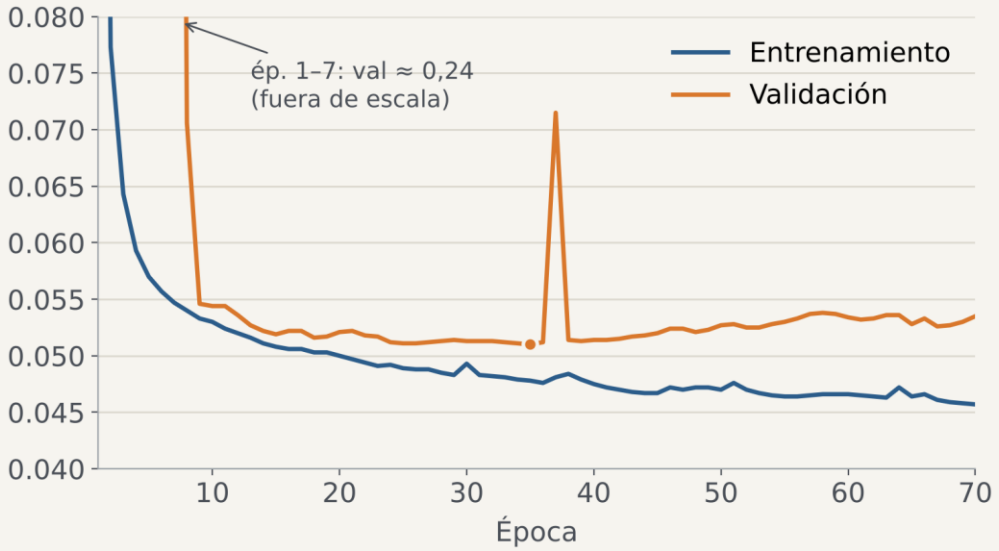
ENTRENAMIENTO

El AE es estable; la VAE tarda en arrancar

AE · pérdida MAE



VAE · pérdida MAE + KL



La validación de la VAE se atasca 7 épocas y, tras su mínimo en la época 35, empieza a subir: sobreajuste. Con **early stopping** habríamos parado ahí.

ANÁLISIS VISUAL · RECONSTRUCCIÓN

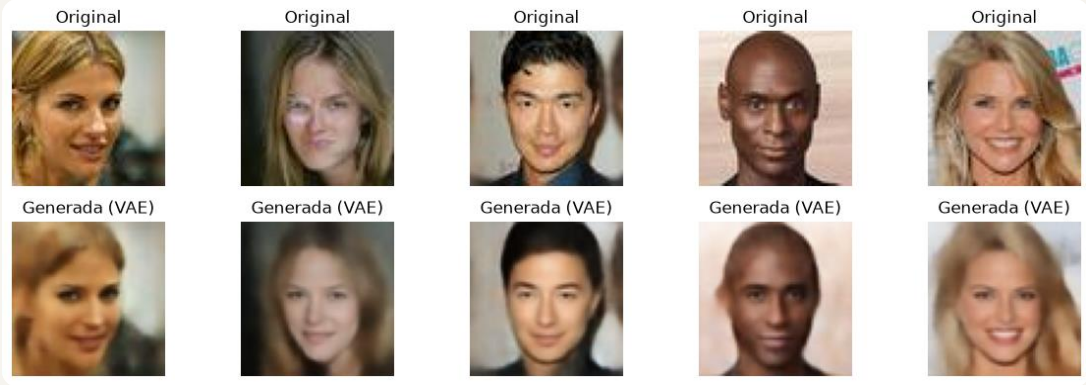
El AE copia mejor; la VAE suaviza

AE



Conserva identidad, sonrisa, color de pelo y fondo. Pierde detalle fino: rizos, pendientes, textura de piel.

VAE



Pose y expresión correctas, pero más borrosa: cambia fondos, tonos de piel y rasgos finos.

La KL obliga a la VAE a no usar todo el espacio latente para memorizar: **pierde nitidez a cambio de un espacio latente ordenado**.

COMPETICIÓN DE KAGGLE

Envío	Cómo se generan las 200 imágenes	Versión MSE	Final (MAE)
AE · reconstr.	Caras del dataset pasadas por el AE	77,24	73,93
VAE · reconstr.	Caras del dataset pasadas por la VAE	93,18	75,62
AE · aleatorio	Decoder sobre z ~ N(μ, σ)	121,35	116,84
VAE · aleatorio	Decoder sobre z ~ N(μ, σ)	116,00	124,19

Mejor envío: AE reconstr., 73,93

Las reconstrucciones copian caras reales, así que se parecen mucho más al dataset.

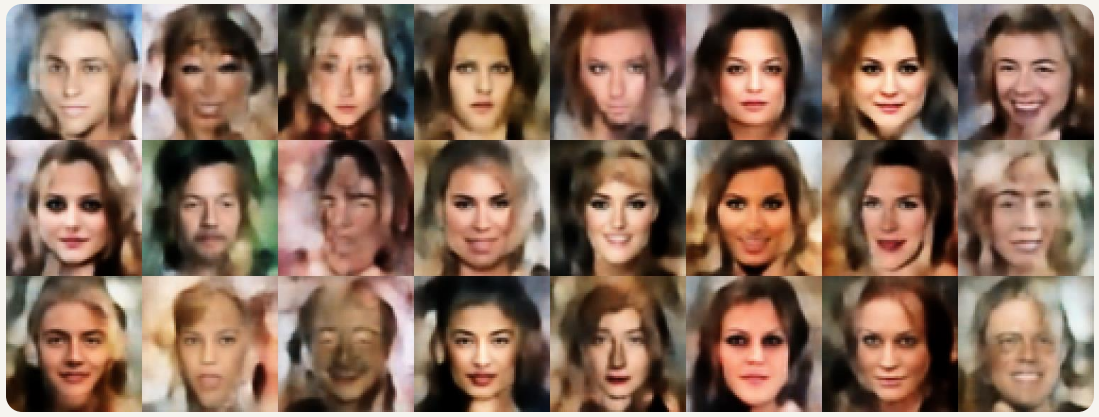
Observación

Con MAE mejoran tres envíos, pero la VAE aleatoria empeora (116,00 → 124,19): la KL pesa menos y genera peor.

ANÁLISIS VISUAL · CARAS NUEVAS FUERA DEL DATASET

Personas que no existen, mezcla de 30.000 caras

AE



VAE



1 · Codificar

Las 30.000 caras pasan por el encoder; nos quedamos con μ.

2 · Medir

Media y desviación de cada una de las 128 dimensiones.

3 · Muestrear

200 vectores z ~ N(media, desv.): puntos nuevos del espacio.

4 · Decodificar

El decoder convierte cada z en una cara de 64×64.

CONCLUSIONES

Los modelos reconstruyen bien, pero generar caras nuevas sigue siendo difícil

AE

Con stride 2, BN, LeakyReLU y MAE reconstruye mejor y genera caras reconocibles, con algunos huecos.

VAE

Con MAE: más nítida que antes, pero su espacio latente se ordena menos.

35–45

épocas bastaban: después solo baja el error de entrenamiento.